Entregable I: predicción temprana del tiempo de entrega y del retraso en pedidos de comercio electrónico

Cristian Echeverry, Esteban Andrés Castaño y Mateo Aguirre

***Resumen*—Este entregable formula un sistema de aprendizaje de máquina para anticipar, desde el momento de la compra, el tiempo de entrega de un pedido y la probabilidad de incumplir la fecha prometida. Se emplea el conjunto público de comercio electrónico de Olist, organizado como una base relacional de cerca de cien mil pedidos. Se definen dos tareas supervisadas complementarias: regresión de días hasta la entrega y clasificación binaria del retraso. La preparación propuesta agrega las tablas a una fila por pedido, trata faltantes dentro de un *pipeline*, codifica variables categóricas y excluye toda señal posterior a la compra. El estado del arte revisa cuatro artículos de revista y sustenta la comparación posterior de modelos lineales, no paramétricos, ensambles, redes neuronales y máquinas de soporte vectorial.**

***Index Terms*—Aprendizaje supervisado, logística de comercio electrónico, predicción de tiempo de entrega, clasificación de retrasos, conjunto Olist, fuga de información.**

I. Descripción del problema

I-A. Contexto, pregunta y utilidad

La experiencia de entrega afecta la satisfacción del cliente, la carga de atención y la planeación logística. La pregunta de investigación es: *¿puede predecirse, al registrar una compra, cuánto tardará el pedido y si llegará después de la fecha estimada?* Una respuesta temprana permitiría priorizar pedidos, comunicar riesgos y planear capacidad antes de que ocurra el incumplimiento.

Se plantean dos salidas complementarias. La regresión estima la duración absoluta; la clasificación expresa el riesgo respecto a la promesa. No son equivalentes: un envío largo puede llegar a tiempo si la promesa contempla esa duración, mientras uno corto puede incumplir una fecha más exigente.

I-B. Composición de la base de datos

Se usa *Brazilian E-Commerce Public Dataset by Olist* [1], con 99 441 pedidos realizados en Brasil entre 2016 y 2018. La fuente distribuye nueve archivos CSV relacionados mediante identificadores. La Tabla I resume su función. La unidad analítica elegida es el pedido (`order_id`); artículos y pagos se agregan antes de unirlos para impedir la duplicación de observaciones.

La tabla analítica resultante contiene 20 predictores conocidos al momento de la compra: 4 categóricos y 16 numéricos. La Tabla II describe cada variable, su tipo y su significado, abarcando localización del cliente, atributos agregados del producto, estructura del pago y componentes del calendario de compra.

Cuadro I
Composición lógica del conjunto Olist.

Fuente	Contenido y uso
Pedidos	Fechas de compra, promesa, despacho y entrega; construcción de etiquetas.
Clientes	Ciudad, estado y código postal aproximado del destino.
Artículos	Productos, vendedores, precio y flete; agregación por pedido.
Productos	Categoría, dimensiones y peso; agregación por pedido.
Pagos	Tipo, cuotas y valor; agregación por pedido.
Vendedores	Localización de origen; conteos y diversidad por pedido.
Reseñas	Evaluación posterior; se excluye para evitar fuga de información.
Geolocalización	Coordenadas por prefijo postal; enriquecimiento opcional.
Traducción	Equivalencias de categorías de portugués a inglés.

I-C. Faltantes, codificación y control de calidad

Los faltantes se concentran en atributos opcionales del producto, como categoría, peso y dimensiones; adicionalmente, una fracción menor de pedidos carece de fechas finales y no admite construcción de etiqueta. El notebook `01_eda.ipynb` reporta la auditoría por columna con porcentajes exactos. Se descartan únicamente registros sin las fechas indispensables o con duraciones negativas. Las variables numéricas restantes se imputan con la mediana del conjunto de entrenamiento y las categóricas con su moda. Después, los campos numéricos se estandarizan y los categóricos se convierten mediante *one-hot encoding*, ignorando categorías nuevas en validación o prueba.

Todas las transformaciones se aprenden exclusivamente con entrenamiento dentro de un *pipeline*. Se excluyen identificadores, reseñas, estado final, fecha de entrega, fecha de despacho y cualquier señal generada después de comprar. La fecha estimada sí está disponible en ese instante y se representa como días prometidos desde la compra.

I-D. Paradigma y variables objetivo

Se adopta aprendizaje supervisado porque los pedidos históricos entregados permiten construir etiquetas observadas. Para regresión y clasificación se definen, respectivamente,

$$y_{reg} = \frac{t_{entrega} - t_{compra}}{86400}, \qquad y_{cls} = \mathbb{I}(t_{entrega} > t_{estimada}). \tag{1}$$

Modelos y Simulación de Sistemas II, Departamento de Ingeniería de Sistemas, Universidad de Antioquia (UdeA).

Cuadro II
VARIABLES PREDICTORAS DISPONIBLES AL MOMENTO DE LA COMPRA.

Variable	Tipo	Significado
customer_city	Categórica	Ciudad del cliente (∼4 000 valores)
customer_state	Categórica	Estado del cliente (27 siglas)
product_category_name	Categórica	Categoría del producto; moda si hay varios artículos (∼70 categorías)
payment_type	Categórica	Método de pago (tarjeta, boleto, voucher, débito); moda si hay varios registros
payment_installments	Num. entera	Máximo de cuotas registradas
payment_value	Num. continua	Valor pagado total (BRL)
payment_records	Num. entera	Cantidad de registros de pago
item_count	Num. entera	Número de artículos del pedido
seller_count	Num. entera	Vendedores distintos involucrados
total_price	Num. continua	Suma del precio de los artículos (BRL)
total_freight_value	Num. continua	Suma del flete (BRL)
mean_product_weight_g	Num. continua	Peso promedio del producto (g)
mean_product_length_cm	Num. continua	Longitud promedio (cm)
mean_product_height_cm	Num. continua	Altura promedio (cm)
mean_product_width_cm	Num. continua	Ancho promedio (cm)
purchase_year	Num. entera	Año de compra (2016–2018)
purchase_month	Num. entera	Mes de compra (1–12)
purchase_dayofweek	Num. entera	Día de la semana (0–6)
purchase_hour	Num. entera	Hora de compra (0–23)
estimated_delivery_days	Num. continua	Días prometidos (fecha estimada menos compra)

La primera salida se mide en días; la segunda vale uno cuando existe retraso. La formulación dual permite evaluar el error de duración mediante MAE, RMSE y R^2, y el riesgo de retraso mediante exactitud balanceada, precisión, exhaustividad, F_1 y ROC–AUC. Debido al desbalance esperado, la exactitud simple no será el criterio principal.

II. ESTADO DEL ARTE

Wolter y Hanne [2] compararon regresión lineal, SVM y redes neuronales sobre registros de servicios domiciliarios de instalación de muebles y conexiones eléctricas. Usaron partición 80/20 y validación cruzada de cinco pliegues; la red obtuvo los mejores resultados y, en regresión, las configuraciones estables alcanzaron MAE de 8,5–9,5 minutos. También encontraron que PCA redujo el tiempo de entrenamiento y el error.

Rokoss *et al.* [3] estudiaron la determinación de fechas de entrega en producción de lotes pequeños mediante CRISP–DM, regresión y explicaciones SHAP. Los datos provienen de dos empresas manufactureras (mecánica de precisión con 17 máquinas y producción de sellos de caucho con 52 máquinas), con 16 361 órdenes agregadas. Incorporar variables de dominio redujo RMSE de 9,5 a 7,7 días; predecir en una etapa más temprana aumentó el error cerca de 35 %, lo que evidencia la dificultad de restringir la información al instante de decisión.

Hughes *et al.* [4] evaluaron regresión y clasificación de tiempos de parada de reparto sobre registros de GPS de operaciones logísticas en Medellín, Colombia. Compararon modelos mediante MAPE[1] y análisis de duración; KNN fue competitivo al clasificar umbrales. Chu *et al.* [5] integraron predicción basada en datos con optimización de última milla sobre un escenario de reparto con *crowdsourcing*, en el que la asignación conductor–cliente se decide a partir de tiempos predichos: su enfoque *predict-then-optimize* redujo alrededor de 5 % el costo frente a las alternativas de su estudio.

Los cuatro trabajos justifican comparar modelos paramétricos, no paramétricos, ensambles, ANN y SVM; además, motivan validación temporal y reducción dimensional. El aporte diferencial propuesto es trabajar con Olist, limitar estrictamente los predictores al momento de compra y analizar simultáneamente duración e incumplimiento de la promesa.

[1]Error porcentual absoluto medio, $\mathrm{MAPE} = \frac{1}{n}\sum_{i=1}^{n}\left|\frac{y_i-\hat{y}_i}{y_i}\right| \times 100\,\%$.

REFERENCIAS

[1] Olist, "Brazilian e-commerce public dataset by olist," Kaggle dataset, 2018, consultado: 2026-09-24. [Online]. Available: https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce

[2] J. Wolter and T. Hanne, "Prediction of service time for home delivery services using machine learning," *Soft Computing*, vol. 28, pp. 5045–5056, 2024.

[3] A. Rokoss, M. Syberg, L. Tomidei, C. Hülsing, J. Deuse, and M. Schmidt, "Case study on delivery time determination using a machine learning approach in small batch production companies," *Journal of Intelligent Manufacturing*, vol. 35, pp. 3937–3958, 2024.

[4] S. Hughes, S. Moreno, W. F. Yushimito, and G. Huerta-Cánepa, "Evaluation of machine learning methodologies to predict stop delivery times from GPS data," *Transportation Research Part C: Emerging Technologies*, vol. 109, pp. 289–304, 2019.

[5] H. Chu, W. Zhang, P. Bai, and Y. Chen, "Data-driven optimization for last-mile delivery," *Complex & Intelligent Systems*, vol. 9, pp. 2271–2284, 2023.