Entregable II: predicción temprana del tiempo de entrega y del retraso en pedidos de comercio electrónico

Cristian Echeverry, Esteban Andrés Castaño y Mateo Aguirre

***Resumen*—Este entregable formula un sistema de aprendizaje de máquina para anticipar, desde el momento de la compra, el tiempo de entrega de un pedido y la probabilidad de incumplir la fecha prometida. Se emplea el conjunto público de comercio electrónico de Olist, organizado como una base relacional de cerca de cien mil pedidos. Se definen dos tareas supervisadas complementarias: regresión de días hasta la entrega y clasificación binaria del retraso. La preparación propuesta agrega las tablas a una fila por pedido, trata faltantes dentro de un *pipeline*, codifica variables categóricas y excluye toda señal posterior a la compra. El estado del arte revisa cuatro artículos de revista y sustenta la comparación posterior de modelos lineales, no paramétricos, ensambles, redes neuronales y máquinas de soporte vectorial.**

***Index Terms*—Aprendizaje supervisado, logística de comercio electrónico, predicción de tiempo de entrega, clasificación de retrasos, conjunto Olist, fuga de información.**

I. Descripción del problema

La experiencia de entrega afecta la satisfacción del cliente, la carga de atención y la planeación logística. La pregunta de investigación es: *¿puede predecirse, al registrar una compra, cuánto tardará el pedido y si llegará después de la fecha estimada?* Una respuesta temprana permitiría priorizar pedidos, comunicar riesgos y planear capacidad antes de que ocurra el incumplimiento.

Se plantean dos salidas complementarias. La regresión estima la duración absoluta; la clasificación expresa el riesgo respecto a la promesa. No son equivalentes: un envío largo puede llegar a tiempo si la promesa contempla esa duración, mientras uno corto puede incumplir una fecha más exigente.

Se usa *Brazilian E-Commerce Public Dataset by Olist* [1], con 99 441 pedidos realizados en Brasil entre 2016 y 2018. La fuente distribuye nueve archivos CSV relacionados mediante identificadores. La Tabla I resume su función. La unidad analítica elegida es el pedido (`order_id`); artículos y pagos se agregan antes de unirlos para impedir la duplicación de observaciones.

La tabla analítica resultante contiene 20 predictores conocidos al momento de la compra: 4 categóricos y 16 numéricos. La Tabla II describe cada variable, su tipo y su significado, abarcando localización del cliente, atributos agregados del producto, estructura del pago y componentes del calendario de compra.

Los faltantes se concentran en atributos opcionales del producto, como categoría, peso y dimensiones; adicionalmente, una fracción menor de pedidos carece de fechas finales y no admite construcción de etiqueta. El notebook `01_eda.ipynb` reporta la auditoría por columna con porcentajes exactos. Se descartan únicamente registros sin las fechas indispensables o con duraciones negativas. Las variables numéricas restantes se imputan con la mediana del conjunto de entrenamiento y se estandarizan por puntaje z; las categóricas se imputan con su moda.

Cuadro I
Composición lógica del conjunto Olist.

Fuente	Contenido y uso
Pedidos	Fechas de compra, promesa, despacho y entrega; construcción de etiquetas.
Clientes	Ciudad, estado y código postal aproximado del destino.
Artículos	Productos, vendedores, precio y flete; agregación por pedido.
Productos	Categoría, dimensiones y peso; agregación por pedido.
Pagos	Tipo, cuotas y valor; agregación por pedido.
Vendedores	Localización de origen; conteos y diversidad por pedido.
Reseñas	Evaluación posterior; se excluye para evitar fuga de información.
Geolocalización	Coordenadas por prefijo postal; enriquecimiento opcional.
Traducción	Equivalencias de categorías de portugués a inglés.

Las cuatro variables categóricas se codifican de forma diferenciada según su cardinalidad, siguiendo el principio de preservar señal sin degradar la razón muestras/predictores. `payment_type` (cuatro valores) y `customer_state` (27 estados brasileños) se transforman mediante codificación *one-hot*, apropiada para cardinalidad baja y moderada. `product_category_name` (aproximadamente 70 categorías) también se codifica *one-hot*, agrupando previamente en una clase "otros" aquellas categorías con frecuencia por debajo de un umbral mínimo para evitar columnas casi vacías. `customer_city`, con cerca de 4 000 valores distintos, no admite *one-hot* directo sin inflar en exceso el espacio de predictores; se reemplaza por codificación de frecuencia (número de pedidos observados por ciudad en entrenamiento), que preserva la señal de densidad logística sin ampliar la dimensionalidad. En todos los casos, las categorías no vistas en entrenamiento se tratan como valor por defecto en validación y prueba (`handle_unknown='ignore'` en `scikit-learn`).

Todas las transformaciones se aprenden exclusivamente con entrenamiento dentro de un *pipeline*. Se excluyen identificadores, reseñas, estado final, fecha de entrega, fecha de despacho y

Modelos y Simulación de Sistemas II, Departamento de Ingeniería de Sistemas, Universidad de Antioquia (UdeA).

Cuadro II
VARIABLES PREDICTORAS DISPONIBLES AL MOMENTO DE LA COMPRA. LOS VALORES MONETARIOS SE EXPRESAN EN REALES BRASILEÑOS (BRL).

Variable	Tipo	Significado
`customer_city`	Categórica	Ciudad del cliente (∼4 000 valores)
`customer_state`	Categórica	Estado del cliente (27 siglas)
`product_category_name`	Categórica	Categoría del producto; moda si hay varios artículos (∼70 categorías)
`payment_type`	Categórica	Método de pago (tarjeta, boleto, voucher, débito); moda si hay varios registros
`payment_installments`	Num. entera	Máximo de cuotas registradas
`payment_value`	Num. continua	Valor pagado total (BRL)
`payment_records`	Num. entera	Cantidad de registros de pago
`item_count`	Num. entera	Número de artículos del pedido
`seller_count`	Num. entera	Vendedores distintos involucrados
`total_price`	Num. continua	Suma del precio de los artículos (BRL)
`total_freight_value`	Num. continua	Suma del flete (BRL)
`mean_product_weight_g`	Num. continua	Peso promedio del producto (g)
`mean_product_length_cm`	Num. continua	Longitud promedio (cm)
`mean_product_height_cm`	Num. continua	Altura promedio (cm)
`mean_product_width_cm`	Num. continua	Ancho promedio (cm)
`purchase_year`	Num. entera	Año de compra (2016–2018)
`purchase_month`	Num. entera	Mes de compra (1–12)
`purchase_dayofweek`	Num. entera	Día de la semana (0–6)
`purchase_hour`	Num. entera	Hora de compra (0–23)
`estimated_delivery_days`	Num. continua	Días prometidos (fecha estimada menos compra)

cualquier señal generada después de comprar. La fecha estimada sí está disponible en ese instante y se representa como días prometidos desde la compra.

Se adopta aprendizaje supervisado porque los pedidos históricos entregados permiten construir etiquetas observadas. Para regresión y clasificación se definen, respectivamente,

$$y_{reg} = \frac{t_{entrega} - t_{compra}}{86400}, \qquad y_{cls} = \mathbb{I}(t_{entrega} > t_{estimada}). \tag{1}$$

La primera salida se mide en días; la segunda vale uno cuando existe retraso. La formulación dual permite evaluar el error de duración mediante el error absoluto medio (MAE, *mean absolute error*), la raíz del error cuadrático medio (RMSE, *root mean squared error*) y el coeficiente de determinación R^2; y el riesgo de retraso mediante exactitud balanceada, precisión, exhaustividad, medida F_1 y el área bajo la curva característica operativa del receptor (ROC–AUC, *receiver operating characteristic – area under the curve*). Debido al desbalance esperado, la exactitud simple no será el criterio principal.

II. ESTADO DEL ARTE

Wolter y Hanne [2] compararon regresión lineal, máquinas de vectores de soporte (SVM, *support vector machines*) y redes neuronales sobre aproximadamente 35 000 registros de seis meses de operación de un transportista de última milla, cubriendo tres categorías de servicio: entrega estándar, entrega con ensamble de muebles y entrega con instalación eléctrica. Usaron partición 80/20 y validación cruzada de cinco pliegues; la red obtuvo los mejores resultados y, en regresión, las configuraciones estables alcanzaron MAE de 8,5–9,5 minutos. También encontraron que el análisis de componentes principales (PCA, *principal component analysis*) redujo drásticamente el tiempo de entrenamiento –cerca de un orden de magnitud– con MAE comparable.

Rokoss *et al.* [3] estudiaron la determinación de fechas de entrega en producción de lotes pequeños mediante la metodología estándar *Cross-Industry Standard Process for Data Mining* (CRISP–DM), con partición 90/10 y validación cruzada por ventana rodante que respeta el orden cronológico de las órdenes. Compararon regresión lineal, árbol de decisión, bosque aleatorio, SVM, red neuronal y *gradient boosting* (XGBoost); el último resultó el mejor modelo. Los datos provienen de dos empresas manufactureras alemanas (mecánica de precisión con 17 máquinas, 16 361 órdenes; y sellos de caucho con 52 máquinas, 2 632 órdenes). Incorporar variables derivadas de modelos cuantitativos logísticos redujo el RMSE de 9,5 a 7,7 días hábiles; predecir en una etapa más temprana aumentó el error cerca de 50 % relativo, lo que evidencia la dificultad de restringir la información al instante de decisión. Los autores usan además las métricas normalizadas NRMSE y NMAE para comparar entre empresas, y explican la importancia de las variables mediante valores de Shapley (SHAP, *SHapley Additive exPlanations*).

Hughes *et al.* [4] evaluaron la predicción de tiempos de parada de reparto a partir de registros del sistema de posicionamiento global (GPS, *global positioning system*) de la operación de distribución de productos lácteos de una empresa que opera en Medellín, Colombia, entre febrero de 2016 y abril de 2017. El conjunto resultante comprende 2 760 clientes, 202 tours y 1 487 paradas, caracterizadas por variables como demanda, tipo de calle, nivel de tráfico, zona urbana, posición en la secuencia del tour, franja horaria y distancias desde la parada previa. El trabajo contrasta tres familias de modelos: regresión con aprendizaje de máquina (Lasso, Ridge, red elástica, red neuronal y *gradient boosting* XGBoost); clasificación supervisada (regresión logística, árbol, Bayes ingenuo, SVM, K-vecinos más cercanos (KNN, *k-nearest neighbors*), red neuronal, *boosting*, *bagging* y ensambles de dos niveles); y modelos paramétricos de duración (exponencial, Weibull y log-normal) junto con el modelo semi-paramétrico de Cox. La validación se realiza por validación cruzada estratificada en diez pliegues; los errores se reportan como error cuadrático medio (MSE) y error porcentual absoluto medio (MAPE)[1] para regresión, y exactitud y F_1 para clasificación. El modelo log-normal alcanzó el menor MAPE en regresión (75,80±9,00) y superó a los modelos de aprendizaje de máquina en error absoluto; en clasificación, KNN con umbral de 40 minutos fue el mejor ($F_1 = 0{,}825 \pm 0{,}026$). Los autores concluyen además que un esquema jerárquico que combina clasificación y regresión mejora la predicción cuando la clasificación de primer nivel es correcta.

Chu *et al.* [5] integraron predicción basada en datos con optimización de última milla, motivados por el problema de las plataformas de entrega de comida en línea, en el que

[1] $\mathrm{MAPE} = \frac{1}{n}\sum_{i=1}^{n}\left|\frac{y_i - \hat{y}_i}{y_i}\right| \times 100\,\%$.

Cuadro III
SÍNTESIS COMPARATIVA DE LOS CUATRO TRABAJOS REVISADOS EN EL ESTADO DEL ARTE.

Trabajo	Dominio y datos	Tarea	Modelos y validación	Mejor resultado	Hallazgo clave
Wolter y Hanne [2]	Entrega a domicilio (estándar, ensamble de muebles, instalación eléctrica); ∼35 000 registros, 6 meses.	Regresión del tiempo de servicio.	LR, SVM, red neuronal; 80/20 y validación cruzada de 5 pliegues; PCA opcional.	Red neuronal con MAE 8,5–9,5 min.	PCA reduce el tiempo de entrenamiento cerca de un orden de magnitud con MAE comparable.
Rokoss *et al.* [3]	Producción de lotes pequeños, Alemania: mecánica de precisión (16 361 órdenes) y sellos de caucho (2 632).	Regresión de la fecha de entrega.	LR, árbol, RF, SVM, red neuronal, XGBoost; 90/10 con validación por ventana rodante; SHAP.	XGBoost con RMSE 7,7 días hábiles (reducido desde 9,5 con variables de dominio).	Adelantar la predicción aumenta el error cerca de 50 % relativo.
Hughes *et al.* [4]	Distribución de lácteos, Medellín, Colombia; 2 760 clientes, 202 tours, 1 487 paradas (feb 2016–abr 2017).	Regresión y clasificación del tiempo de parada.	Reg.: Lasso, Ridge, elástica, NN, XGBoost. Clf.: logística, árbol, Bayes, SVM, KNN, NN, *boosting*, *bagging*, ensambles. Duración: exponencial, Weibull, log-normal, Cox. 10 pliegues estratificados.	Log-normal con MAPE 75,80±9,00 (reg.); KNN a 40 min con $F_1 = 0{,}825 \pm 0{,}026$ (clf.).	Los modelos de duración superan al aprendizaje de máquina en error absoluto; un esquema jerárquico clasificación–regresión mejora si la clasificación es correcta.
Chu *et al.* [5]	Motivación en plataformas de entrega de comida en línea; experimentos sobre datos sintéticos (15 clientes, 3 conductores).	Predicción de tiempo y ruteo con capacidad (CVRP) acoplados.	Regresión lineal con penalización ridge bajo pérdida SPO+; *simulated annealing* para el VRP; 10 000 muestras de entrenamiento y 1 000 simulaciones de prueba.	SPO+ con costo total de viaje ∼5 % menor que mínimos cuadrados y valor esperado.	Una pérdida construida con el error de decisión supera al *predict-then-optimize* clásico.

la asignación conjunta de órdenes y el ruteo con capacidad (CVRP) debe decidirse a partir de tiempos de viaje predichos. Formulan la predicción como una regresión lineal con penalización ridge entrenada bajo el marco *smart predict-then-optimize* (SPO+), cuya función de pérdida se construye con el error de decisión en lugar del error de predicción; el ruteo se resuelve con *simulated annealing*, y ambos se iteran para capturar el efecto mutuo entre tiempos y rutas. Los experimentos computacionales se realizan sobre datos sintéticos generados según el protocolo de Elmachtoub y Grigas, con 15 clientes, 3 conductores heterogéneos, 10 000 muestras de entrenamiento y 1 000 simulaciones de prueba. En ese escenario, SPO+ alcanzó un costo total de viaje aproximadamente 5 % menor que el *predict-then-optimize* clásico por mínimos cuadrados y que el modelo de optimización por valor esperado.

Los cuatro trabajos justifican comparar modelos paramétricos, no paramétricos, ensambles, redes neuronales artificiales (ANN, *artificial neural networks*) y SVM; además, motivan validación temporal y reducción dimensional. La Tabla III sintetiza y contrasta los cuatro estudios revisados. El aporte diferencial propuesto es trabajar con Olist, limitar estrictamente los predictores al momento de compra y analizar simultáneamente duración e incumplimiento de la promesa.

REFERENCIAS

[1] Olist, "Brazilian e-commerce public dataset by olist," Kaggle dataset, 2018, consultado: 2026-09-24. [Online]. Available: https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce

[2] J. Wolter and T. Hanne, "Prediction of service time for home delivery services using machine learning," *Soft Computing*, vol. 28, pp. 5045–5056, 2024.

[3] A. Rokoss, M. Syberg, L. Tomidei, C. Hülsing, J. Deuse, and M. Schmidt, "Case study on delivery time determination using a machine learning approach in small batch production companies," *Journal of Intelligent Manufacturing*, vol. 35, pp. 3937–3958, 2024.

[4] S. Hughes, S. Moreno, W. F. Yushimito, and G. Huerta-Cánepa, "Evaluation of machine learning methodologies to predict stop delivery times from GPS data," *Transportation Research Part C: Emerging Technologies*, vol. 109, pp. 289–304, 2019.

[5] H. Chu, W. Zhang, P. Bai, and Y. Chen, "Data-driven optimization for last-mile delivery," *Complex & Intelligent Systems*, vol. 9, pp. 2271–2284, 2023.