

Entregable II: entrenamiento, evaluación y reducción dimensional para la predicción de entregas

Cristian Echeverry, Esteban Andrés Castaño y Mateo Aguirre

Resumen—Este entregable implementa y evalúa la solución propuesta para anticipar la duración y el retraso de pedidos de comercio electrónico. Sobre una muestra temporal de 15 000 pedidos de Olist se comparan cinco familias: modelos paramétricos, vecinos cercanos, bosque aleatorio, red neuronal y máquinas de soporte vectorial. En prueba futura, LinearSVR obtuvo MAE de 4,60 días (IC95 %: 4,43–4,73). Para clasificación, la regresión logística alcanzó ROC–AUC de 0,727 y exhaustividad de 0,964, aunque con baja precisión. PCA redujo 80 variables transformadas a 27 y UMAP a 10; la reducción no mejoró la clasificación y UMAP conservó aproximadamente el desempeño de regresión. El cambio entre validación y prueba evidencia deriva temporal y la necesidad de recalibrar antes del despliegue.

Index Terms—regresión, clasificación, validación temporal, PCA, UMAP, logística.

I. ENTRENAMIENTO Y EVALUACIÓN

I-A. Configuración experimental

Se empleó el conjunto público Olist [1]. Los pedidos se ordenaron por fecha y se tomó una muestra de 15 000 observaciones repartida a lo largo de todo el periodo. La separación se hizo sin barajar: 60 % entrenamiento, 20 % validación y 20 % prueba futura. Los hiperparámetros se seleccionaron con `TimeSeriesSplit` de tres pliegues dentro del bloque de desarrollo; luego cada modelo se reajustó con el 80 % inicial y se evaluó una sola vez en prueba. Los intervalos de confianza se calcularon con 500 réplicas *bootstrap*.

Los predictores se restringieron a información disponible al comprar. La imputación, el escalado y la codificación *one-hot* se aprendieron solo con entrenamiento mediante *pipelines*. Las etiquetas fueron días entre compra y entrega para regresión, e indicador de entrega posterior a la fecha prometida para clasificación.

Para regresión se reportan $MAE = n^{-1} \sum |y_i - \hat{y}_i|$, $RMSE = \sqrt{n^{-1} \sum (y_i - \hat{y}_i)^2}$ y $R^2 = 1 - \sum (y_i - \hat{y}_i)^2 / \sum (y_i - \bar{y})^2$. Para clasificación se usan exactitud balanceada, precisión, exhaustividad, $F_1 = 2PR/(P + R)$ y ROC–AUC. MAE es interpretable en días; RMSE penaliza errores grandes; ROC–AUC evalúa ordenamiento sin fijar umbral y F_1 equilibra precisión y cobertura de la clase minoritaria.

I-B. Resultados de los modelos

En la búsqueda temporal de regresión, LinearSVR con $C = 1$ logró el menor MAE medio (5,74); $C = 0,1$ obtuvo 5,78. Ridge favoreció $\alpha = 10$ (6,04), KNN mejoró al pasar de 7 a




Figura 1. Prueba: MAE de regresión (izquierda, menor es mejor) y ROC–AUC de clasificación (derecha, mayor es mejor).

25 vecinos (6,37 a 6,15), y limitar el bosque a profundidad 12 fue ligeramente mejor que dejarlo crecer. La MLP de una capa fue más estable que (64, 32). En clasificación, el bosque limitado lideró el ROC–AUC de validación cruzada (0,615); KNN y MLP tendieron a ignorar la clase minoritaria.

LinearSVR fue el regresor más consistente, con MAE de prueba de 4,60 días (IC95 %: 4,43–4,73). El MAE nulo de entrenamiento de KNN y la brecha del bosque evidencian sobreajuste. Los R^2 negativos en prueba indican cambio temporal: la media del periodo futuro vence a los modelos en error cuadrático, aunque el MAE siga siendo informativo.

El bosque fue campeón de validación, pero cayó a ROC–AUC 0,477 (IC95 %: 0,434–0,518) en prueba. Logística y SVC generalizaron mejor: detectaron 96,4 % de retrasos, aunque solo cerca de 7 % de sus alertas fueron correctas. El umbral debe calibrarse según el costo de las falsas alarmas. La MLP tuvo mayor precisión, pero omitió casi todos los retrasos.

II. REDUCCIÓN DE DIMENSIONALIDAD

II-A. Análisis individual

La importancia por permutación del campeón de regresión fue dominada por `estimated_delivery_days` (0,698) y `customer_state` (0,306); después aparecieron ciudad, mes, flete y categoría (0,022–0,033). En clasificación, la promesa estimada fue la señal principal (0,089), seguida por día de semana, longitud del producto, cantidad y categoría (0,004–0,008). Variables cercanas a cero son candidatas a eliminación, pero deben confirmarse con ablación temporal porque la colinealidad o la deriva pueden producir importancias negativas.

II-B. PCA y UMAP sobre los dos mejores modelos

PCA retuvo 95 % de la varianza y redujo 80 variables transformadas a 27 (66,25 %). UMAP usó 10 componentes y redujo 87,5 %. Se aplicaron a LinearSVR y KNN en regresión,

Cuadro I
FAMILIAS Y GRILLA DE HIPERPARÁMETROS EVALUADA EN AMBAS TAREAS.

Familia	Modelo	Regresión	Clasificación
Paramétrico	Ridge / logística	$\alpha \in \{0,1, 10\}$	$C \in \{0,2, 2\}$; pesos balanceados
No paramétrico	KNN	$k \in \{7, 25\}$; distancia	$k \in \{9, 31\}$; distancia
Ensamble	Random Forest	profundidad $\in \{12, \text{sin límite}\}$; hoja mínima 2	misma grilla; pesos balanceados
Red neuronal	MLP	capas (48) o (64, 32); $\alpha = 10^{-4}$	misma arquitectura y regularización
SVM	LinearSVR LinearSVC	$C \in \{0,1, 1\}$; $\epsilon = 0,1$	$C \in \{0,1, 1\}$; pesos balanceados

Cuadro II
REGRESIÓN: DESEMPEÑO POR PARTICIÓN Y PRUEBA FUTURA.

Modelo	MAE _{tr}	MAE _{val}	MAE _{test}	RMSE / R ²
LinearSVR	5,06	5,88	4,60	6,08 / -0, 03
KNN	0,00	6,49	5,04	6,44 / -0, 16
MLP	5,10	6,67	5,59	7,21 / -0, 45
Ridge	5,29	6,81	6,36	7,65 / -0, 63
Random Forest	3,88	7,16	4,71	6,28 / -0, 10

Cuadro III
CLASIFICACIÓN: ROC–AUC POR PARTICIÓN Y MÉTRICAS DE PRUEBA.

Modelo	AUC _{tr}	AUC _{val}	AUC _{test}	BACC	F ₁
Random Forest	0,980	0,686	0,477	0,505	0,080
KNN	1,000	0,620	0,488	0,500	0,000
Logística	0,748	0,605	0,727	0,603	0,130
LinearSVC	0,747	0,602	0,725	0,608	0,132
MLP	0,562	0,561	0,659	0,518	0,073

Cuadro IV
REDUCCIÓN Y DESEMPEÑO EN PRUEBA.

Tarea	Método/modelo	Dim.	Red.	Métrica
Reg.	PCA / LinearSVR	27	66,3 %	MAE 4,86
Reg.	PCA / KNN	27	66,3 %	MAE 5,37
Reg.	UMAP / LinearSVR	10	87,5 %	MAE 4,67
Reg.	UMAP / KNN	10	87,5 %	MAE 5,74
Clas.	PCA / RF	27	66,3 %	AUC 0,573
Clas.	PCA / KNN	27	66,3 %	AUC 0,453
Clas.	UMAP / RF	10	87,5 %	AUC 0,517
Clas.	UMAP / KNN	10	87,5 %	AUC 0,524




Figura 2. Desempeño después de PCA y UMAP; la línea punteada corresponde al mejor modelo sin reducción.

y a Random Forest y KNN en clasificación, seleccionados por validación.

PCA aumentó 0,27 días el MAE de LinearSVR. UMAP conservó mejor el desempeño con 70 variables menos, pero no superó de forma concluyente el intervalo del modelo completo. Ninguna reducción reparó la inestabilidad temporal de clasificación. Se recomienda el espacio completo para trazabilidad y UMAP solo cuando el ahorro computacional justifique sacrificar interpretabilidad.

III. REPRODUCIBILIDAD

El cuaderno instala dependencias, descarga Olist, entrena las diez configuraciones por tarea, calcula intervalos, ejecuta PCA/UMAP y exporta tablas. Puede ejecutarse en

Google Colab: Entregable II completo.

Repositorio: <https://github.com/Cde571/LogisTech-Modelos-Simulacion-II>. El video de defensa de diez minutos debe presentar problema, método, resultados, reducción y conclusiones, y añadirse cuando el equipo disponga del enlace.

IV. CONCLUSIONES

Se cumplieron las cinco familias, la separación entrenamiento–validación–prueba, intervalos de confianza, análisis individual y reducción con PCA y UMAP. LinearSVR fue la mejor opción para duración. Para alertas, logística/SVC discriminaron mejor en el futuro que el bosque elegido

en validación, pero la precisión baja exige calibración y monitoreo de deriva. UMAP comprimió 87,5 % conservando aproximadamente la regresión; la reducción no benefició la clasificación.

REFERENCIAS

- [1] Olist, “Brazilian e-commerce public dataset by olist,” Kaggle dataset, 2018, consultado: 2026-09-24. [Online]. Available: <https://www.kaggle.com/datasets/olistbr/brazilian-e-commerce>